

DATA ANALYST

ML ENGINEER

2026.09

PORTFOLIO

송이현
YIHYUN SONG

CONTENTS

01 About Me

02 Education & Experience

03 Skills & Certificates

04 Projects

PROJECTS

- 01 라이프로그·건강조사 데이터 기반 치매 예측 및 비대면 음성 인지 검사 플랫폼 : 또릿
- 02 CNC 센서 데이터 기반 가공 공정 불량 예측
- 03 edX MOOC 수강생 데이터 기반 학습 행동 분석
- 04 IT 아웃소싱 플랫폼 데이터 기반 매출 개선 분석
- 05 지역별 기상 데이터 기반 열수요 예측
- 06 CNN 기반 Doodle 이미지 분류
- 07 H&M 이커머스 데이터 기반 구매 행동 분석

ABOUT ME

데이터와 AI로 가치를 만드는 송이현입니다.

데이터 분석과 머신러닝·딥러닝 모델링을 기반으로 문제 정의부터 데이터 전처리, 모델 개발, 서비스 구현까지 경험했습니다.

분석에 머무르지 않고 데이터에서 문제를 발견하고, AI 기술을 실제 서비스로 연결해 실질적인 해결책을 만드는 것을 지향합니다.

학력 홍익대학교 컴퓨터공학과 (2021.03 - 2027.02, GPA : 3.65/4.5)

인턴 Greybox - Project Management Intern (2025.11 - 2026.02)

교육 내일배움캠프 데이터분석 6기 수료 (2025.03 - 2025.07)

수상 DSA Business Data Analysis Project 최우수상 (2024.02)



EDUCATION & EXPERIENCE



홍익대학교 컴퓨터공학과

2021.03 – 2027.02 (졸업 예정) GPA : 3.65/4.5

주요 이수 과목

기초데이터베이스 · 기계학습기초 · 기계학습심화 · 자료구조
알고리즘분석 · 객체지향프로그래밍 · 소프트웨어공학 · 운영체제

교육

내일배움캠프 데이터분석 6기 2025.03 – 2025.07
SQL·Python·머신러닝·Tableau 데이터 분석 실무 과정 수료

DSA Python 활용 실무 데이터 분석 2023.11 – 2024.02
Python 기반 데이터 전처리·분석 및 머신러닝 실무 과정 수료

Greybox | Project Management Intern

2025.11 – 2026.02 (3개월)

데이터 분석과 AI 기술을 활용한 서비스 운영 및 업무 프로세스 개선

- Redash 기반 **데이터 분석 및 운영 대시보드** 구축으로 주요 지표 모니터링
- KoNLPy 기반 **고객 문의 NLP 분석**을 통해 반복 문의 패턴 도출 및 FAQ·문서 개선
- **RAG** 구축 및 **RAG 기반 AI BOT** 개발을 통한 고객 문의 AI 답변 생성
- AI 서비스 **QA 자동화 및 답변 평가 시스템** 구축으로 AI 답변 품질 평가
- **n8n**을 활용한 반복 업무 및 데이터 처리 자동화

SKILLS & CERTIFICATES

Data Analysis

- Python · Pandas · NumPy
- SQL (MySQL)
- 데이터 전처리 · EDA
- 통계 분석 · 가설 검정
- 상관 분석 · 파생변수 설계
- 시계열 데이터 분석

Visualization

- Tableau
- Redash
- Matplotlib · Seaborn
- Dashboard 설계
- KPI · 지표 분석
- 데이터 시각화 · 인사이트 도출

ML / DL

- Scikit-learn
- XGBoost · LightGBM · CatBoost
- TensorFlow · Keras
- LSTM · Transformer
- SMOTE · Optuna
- SHAP
- NLP · LLM · RAG

Tools & Data

- GitHub · Jupyter · VS Code
- MongoDB · AWS S3
- Supabase
- n8n
- Colab

보유 자격증

2026.09	AICE ASSOCIATE
2026.08	PCSQL Lv4 (1000점)
2026.06	GAIQ
2025.06	SQLD
2025.03	ADsP

수상

**DSA Business Data Analysis
Project 최우수상**

2024.02 · IT 아웃소싱 플랫폼 시장 분석

PROJECTS

01

라이프로그·건강조사 데이터 기반 치매 예측 및 비대면 음성 인지검사 플랫폼 : 또릿

라이프로그·건강조사 데이터 기반 치매 예측 모델과 비대면 CIST 검사 서비스 구축

02

CNC 센서 데이터 기반 가공 공정 불량 예측

CNC 센서·공정 데이터 기반 양품/불량 분류 및 SHAP·파생변수 기반 모델 개선

03

edX MOOC 수강생 데이터 기반 학습 행동 분석

64만 건 수강 데이터 및 AARRR 분석과 이해관계자별 Tableau 대시보드 구축

04

IT 아웃소싱 플랫폼 데이터 기반 매출 개선 분석

가격·고객 구조 분석을 통한 전문가 등급제 및 가격 정책 기반 매출 개선안 도출

05

지역별 기상 데이터 기반 열수요 예측

기상·에너지 데이터 기반 변수 설계 및 앙상블·스태킹 모델을 활용한 열수요 예측

06

CNN 기반 Doodle 이미지 분류

Doodle 이미지 데이터 기반 CNN 모델 구현 및 주요 아키텍처별 성능 비교

07

H&M 이커머스 데이터 기반 행동 구매 행동 분석

고객 구매·상품 데이터를 기반으로 구매 패턴 분석 및 매출 개선 전략 도출

PROJECT 01

Project Overview

라이프로그·건강조사 데이터 기반 치매 예측 및 비대면 음성 인지검사 플랫폼 : 도릿
2025.05 – 2025.07 (3개월) · 팀장


Problem

- 고령 인구 비율이 높은 부산의 지역적 특성
 - 산복도로·구릉지 지형으로 고령자의 의료기관 접근성에 제약
- 기존 CIST 검사의 대면 방문 및 전문 인력 의존
 - 정기적인 검사와 지속적인 인지 상태 관리에 한계

→ 음성으로 간편하게 수행하는 비대면 AI CIST 검사와 라이프로그·건강조사 데이터 기반 치매 예측 및 예방 관리 플랫폼 구축

My Role

- 4인 팀의 팀장으로 프로젝트 총괄
- 라이프로그 데이터 전처리·EDA 및 머신러닝·딥러닝 치매 예측 모델링 총괄
- Tableau 대시보드 시각화 총괄 - 치매 위험도·검사 결과·수면/활동 추이



음성 응답 → CLOVA STT → GPT 기반 CIST 분석 → 결과 전송·맞춤 케어로 이어지는 서비스 흐름

Tech Stack

Python

Pandas

Scikit-learn

TensorFlow·Keras

SMOTE

Optuna

Tableau

CLOVA Speech API

OpenAI GPT API

PROJECT 01

EDA



Data

라이프로그 (AI Hub) 웨어러블 기기 수면·활동 데이터
39,300행 × 105열 (약 4개월 수집분)



지역사회건강조사 (질병관리청)
14,516행 × 209열 → 가이드라인 기반 81개 변수 선별

Process

- 라벨 데이터와 이메일 PK 기준 JOIN → 진단(치매/정상) 컬럼 생성
- 응답 코드 정제(7·77·777, 9·99·999 결측 처리)와 정규화, 흡연·우울 점수 파생변수 생성
- Chi² 검정·상관 분석으로 모델링용 30개 변수 선별
- SMOTE 오버샘플링으로 클래스 불균형 보정



진단군별 수면 구조 비교(좌) · 월별 평균 운동 강도 추이(우)



활동 데이터 피어슨 상관관계수 히트맵 (좌) · 수면 데이터 피어슨 상관관계수 히트맵(우)

EDA Insight

- 활동 시간·운동량·활동 점수 간 **강한 양의 상관관계** 확인
- 비활동 시간과 활동 유지 지표 간 **강한 음의 상관관계** 확인
- 수면 시간·중간점·수면 점수 간 양의 상관관계, 불면 관련 지표와 수면 지표 간 **강한 음의 상관관계** 확인
- 치매군은 **전체 수면 시간은 길지만 깊은 수면·REM 수면이 짧고 수면 효율이 낮음**
- 겨울철 운동 강도 감소** 패턴 확인

→ 수면 효율·활동량을 핵심 시계열 Feature로 선별하여 Bi-LSTM 입력에 활용

PROJECT 01

Modeling & Result

트리 기반 ML은 각 행을 독립 샘플로 취급해 시계열의 시간적 의존성을 반영하지 못함

→ 양방향 시퀀스를 학습하는 **Bi-LSTM 적용** (SMOTE + 튜닝)

머신러닝 5종 비교 (Optuna 튜닝 기반)

모델	Precision	Recall	F1-Score
Random Forest	0.66	0.55	0.59
LightGBM	0.66	0.55	0.59
CatBoost	0.63	0.56	0.59
AdaBoost	0.60	0.39	0.44
GBM	0.49	0.21	0.08

→ 트리 계열 성능 한계 확인 후 시계열 딥러닝으로 전환

Bi-LSTM 결과 (하이퍼파라미터 튜닝 기반)

클래스	Precision	Recall	F1-Score
0 (정상)	0.9524	0.7692	0.8511
1 (치매)	0.50	0.8571	0.6316
Accuracy			0.7879

Recall 0.86

치매 판별 재현율
BiLSTM 최적화 + SMOTE

조기 선별 서비스 특성상 치매 환자를 놓치지 않는 것이 중요

→ 소수 클래스 Recall 중심으로 모델 최적화

- ACT·SLEEP 데이터를 이메일+날짜 기준 병합해 3차원 시퀀스 입력 구성
- SMOTE로 학습 데이터 불균형 보정 후 하이퍼파라미터 튜닝 수행

PROJECT 01


Service & Business



Tableau 대시보드 — 활동·수면 / 치매 위험도 / 전화 인지검사 / 치매 예방 게임

Result

- CLOVA STT + GPT 기반 음성 CIST 인지 선별 프로세스를 설계해 비대면 전화 검사 서비스 구현
- 개인별 치매 위험도·검사 결과·수면/활동 추이를 실시간 대시보드로 제공
- 고령 인구·공공 통계 기반 시장성 분석으로 서비스 사업성 검증



Project Overview

Problem



- 불량 원인 파악이 어렵고 공정 중 불량을 사전에 예측할 수 없음
- 데이터 기반 의사결정 시스템 부재 → 센서 데이터 기반 예측·해석 필요

Data

- CNC 장비 센서 데이터(위치·속도·가속도·전류·전압·파워) 25개 실험 + 조건/품질 데이터
- 총 26개 테이블 (5일간 1초 주기 수집)
- 라벨링: 공정 완료 + 육안검사 통과 = 양품(1), 그 외 불량(0)
- 양품 70.7% vs 불량 29.3% 불균형 → **SMOTE 보정 · MinMaxScaler 정규화**

My Role

- EDA·센서/공정 데이터 전처리
- SMOTE·MinMaxScaler를 활용한 데이터 불균형 보정
- LightGBM 모델 개발
- DNN·CNN 모델 개발
- SHAP을 활용한 불량 예측 주요 변수 분석




SMOTE 전후 클래스 분포

불균형 보정

원본 데이터는 양품 70.7% : 불량 29.3%로 불균형

→ SMOTE 오버샘플링으로 50:50 균형을 맞춰
불량 클래스 학습력 확보

Modeling & Result



Confusion Matrix 기반 모델 비교

평가 기준 설계

단순 Accuracy가 아닌 불량 예측률(TN/(FP+TN))·F1·FN 개수를 함께 비교
→ 제조 공정에서 치명적인 "불량품을 양품으로 판정하는 실패(FN)"를 최소화하는 모델을 선택

부스팅 5종 비교

모델	불량 예측률	F1	FN
CatBoost	92.8%	96%	—
XGBoost	92.5%	95%	—
GBM	95.7%	95%	132
AdaBoost	95.6%	95%	102
LightGBM	96.0%	95%	98

LightGBM 최종 선정
불량 예측률 96.0% · F1-Score 95%

False Negative 98개로 최소
→ 불량을 양품으로 놓치는 리스크 최소화

PROJECT 02

Modeling & Result

공장 내 CNC 가공 장비 Data

Data Set	Number of row
experiment_01.csv	1056
experiment_02.csv	1669
experiment_03.csv	1522
experiment_04.csv	533
...	
experiment_22.csv	566
experiment_23.csv	463
experiment_24.csv	2333
experiment_25.csv	566

CNC 실험 별 세팅값 Data

Attributes name	Description
X_ActualPosition	부품의 실제 x 위치
Y_ActualVelocity	부품의 실제 x 속도
Z_ActualAcceleration	부품의 실제 x 가속도
S_CurrentFeedback	스핀들 전류
...	
Machining_Process	스핀들의 순간 공급 속도
M_CURRENT_PROGRAM_NUMBER	프로그램이 CNC에 나열된 번호

1차원 센서 신호를 STFT 스펙트로그램 이미지로 변환 후 CNN(ResNet-50) 입력




실험 결과

DNN
Accuracy 0.887 → 0.967 F1 Score: 0.9393 → 0.9531
학습률·Dropout·손실함수·배치사이즈 단계적 조정

CNN
Accuracy 0.910 → 0.951 F1 Score: 0.9343 → 0.9650
ResNet-50 + Dropout 추가·학습률 조정(0.001 → 0.0001)

PROJECT 02

XAI & Feature Engineering



실패 원인 분석

SHAP 분석 결과 **M_CURRENT_FEEDRATE**의 영향이 압도적
예측 실패 케이스 100건 Waterfall 분석
→ 모든 실패 사례에서 해당 변수의 **강한 음의 영향 확인**
특정 변수 과의존이 실패 주원인

SHAP Summary Plot(좌) · 실패 케이스 Waterfall 분석(우)

Feature Engineering

속도·전류·부하·토크의 물리적 관계를 반영한 파생변수 4종 설계
Torque_Estimate · Load_Increase · Velocity_Current_Ratio · Velocity_Power_Ratio

병합 시 Torque_Estimate가 SHAP 중요도 2위로 상승
→ 파생변수는 기존 변수와 함께 쓸 때 시너지 확인

실험	불량 예측률	F1	FN
기존 변수 (선정)	96.0%	95%	98
파생변수 병합	95.1%	95%	104
파생변수 4개 단독	93.6%	89%	304

Project Overview


edX MOOC 수강생 데이터 기반 학습 행동 분석
2025.05 (1개월) · 팀원

Data & Process

- 2012-2013년 edX 수강 데이터 **641,138건** (Harvard·MIT 16개 강의)
- 결측·이상치 처리 후 수강 **385,155건** · 수강생 **311,905명** 확보
- 파생변수 5종 설계 - **학습 기간·학습 밀도·언어권·강의 분야·연령**
- 수익 모델(수료 인증서)에 맞춰 **수료율을 핵심 KPI**로 정의

My Role

- Tableau 대시보드 구축과 AARR 퍼널 분석 담당
- 사용자 행동 지표 분석 및 데이터 기반 인사이트 도출 수행



변수 간 상관관계 히트맵 — 상관 0.5 이상 변수 필터링(우)

수료 여부 - 성적 상관계수 0.93

활동 지표(nchapters·nevents·참여일수)도 수료와 양의 상관 확인
→ 행동 지표 중심으로 대시보드 KPI·퍼널 단계 설계

3.58%

전체 수료율 (KPI)


수료율이 수익에 직결되는 구조
→ 이탈 구간 진단이 핵심 과제

PROJECT 03

AARR Funnel

AARR 퍼널 전환율


Acquisition: 모든 유입 사용자 (고유 사용자 ID)
Activation: 강의를 실제로 시청한 사용자
Retention: Ndays Act > 1
Revenue: 인증서를 받은 사용자



단계별 전환율

Acquisition	100%
Activation	74.07%
Retention	51.79%
Revenue	4.13%

* Revenue 4.13%는 Acquisition 기준 전체 전환율



참여 일수 분포 - 전체(좌) vs 수료자(우)

전체 수강생은 참여 0~10일에 집중되어 있으며, 수료자는 0~100일 고른 분포


→ 초기 이탈 방지가 수료율 개선의 핵심

Insight


- 유입 후 약 26%가 콘텐츠를 한 번도 시청하지 않고 이탈 → 초기 온보딩 개선 필요
- 활성 사용자의 약 48%가 하루 활동 후 이탈 → 초기 1~3일 리텐션 구조(챌린지·미션) 설계 필요

PROJECT 03


Dashboard



종합 대시보드



마케팅 대시보드



프로덕트 대시보드

Insight

- 이해관계자(마케팅·프로덕트)별 목적에 맞춘 **KPI 대시보드 3종 설계** - Big Number·트리맵·AARR 퍼널·국가별 지도·강의 필터 연동
- 언어권 분석(포르투갈어·아랍어 사용자 비중) 기반 **다국어 지원·현지화 마케팅 제안**
- 성별·연령별 선호 강의 차이 기반 타겟 마케팅, 인기 강의 정기 개설·비인기 강의 리뉴얼 검토 제안

PROJECT 04

Project Overview

Goal

소비자 니즈 기반 차별화 서비스 전략과 가격 측정 모델 수립으로
전분기 대비 10% 이상 매출 증대 목표

Analysis

- 약 12.4만 명 고객·거래 데이터 분석 - 분포·상관·IQR 이상치 확인
- 동일 서비스명 가격이 IQR을 크게 벗어나는 편차 확인 → **적정 가격 기준 부재**
- 매출이 소수 헤비 고객에 집중 - **10건 이상 구매 고객은 전체의 약 2.7%**
- 구매 고객: 20대 약 50% · 남성 73.4% · 유튜브/블로그 유입 다수
- 신속 알람 미사용자 약 80%, 프리미엄 미가입자의 거래 취소가 가입자 대비 약 2배

My Role

- 4인 팀의 **팀장**으로 프로젝트 총괄
- 고객·거래 데이터 전처리 및 EDA
- 고객 구매 패턴 및 매출 구조 분석
- 데이터 기반 **적정 가격 산정 모델** 및 **차별화 서비스 전략** 수립

Tech Stack

Python

pandas·numpy


matplotlib·seaborn

IT 아웃소싱 플랫폼 데이터 기반 매출 개선 분석

2023.11 – 2024.02 (4개월) · 팀장

동종 분야 서비스끼리의 가격 분석

자료1 | L사 동일 서비스명의 가격 분포도




L사의 인기 서비스인 'VBA 프로그램 ~'과 '리눅스 기술지원 ~'의 가격 분포도를 확인한 결과, IQR * 을 상당히 벗어난 값들이 존재함
-> 동종 분야의 서비스이나 다른 가격이 책정되는 경우로 인한 소비자의 불만이 존재하므로, 동종 분야 서비스의 적정 가격 책정 기준 마련 필요

서비스 대분류 별 거래취소 및 판매수 분석


서비스 대분류 별 거래취소여부

서비스 대분류 별 판매수



서비스 대분류 중 홈페이지는 판매수와 거래 취소 수가 모두 높으며, 제시된 서비스 대분류 중 거래취소율이 가장 높음
-> 거래 취소율을 줄이기 위한 홈페이지 서비스 개선 전략 필요


전문가의 프리미엄 서비스 가입여부 별 거래 취소 수 분석



프리미엄 서비스 미가입자의 거래 취소 수가 프리미엄 서비스 가입자보다 2배 정도 많음
-> 전문가 유치 및 거래 취소 수 감소를 위한 프리미엄 서비스 활성화 필요

신속 알람 서비스 사용자 수 분석

자료2 | L사 신속알람서비스 사용자 수



신속 알람 서비스 미사용자의 비율은 약 80%로, 신속 알람 서비스 사용자(약 20%)보다 약 4배 더 많음
-> 고객과 전문가 사이의 소통 활성화를 위한 신속 알람 서비스 홍보 전략 필요

고객 매출 구조 분석

서비스종구매수			
count	124107.000000	25%	1.000000
mean	2.503936	50%	1.000000
std	3.986291	75%	3.000000
min	1.000000	max	96.000000

124017명의 고객 데이터를 분석한 결과,
1. 10건 이상 구매한 고객은 전체 고객의 약 2.7%에 불과한 것으로 확인
2. L사 대부분의 매출 구조는 구매수가 높은 일부 고객들에 의해 지배됨을 확인

고객 특징 분석



1. 경기도, 경상도, 서울시 거주 고객들이 서비스를 많이 구매함
2. 유튜브와 네이버 블로그를 통한 고객의 유입이 높음
3. 구매고객 중 20대 고객이 약 50%를 차지함
4. 남성 고객의 서비스 구매율(73.4%)로, 여성 고객의 서비스 구매율(26.6%)보다 현저히 높음

-> 구매수가 높은 고객들을 지속적으로 유치함과 동시에 구매수가 낮은 고객들의 구매율을 높이기 위한 전략 필요
-> 서비스 구매고객이 많이 분포하는 거주지 및 유입 경로, 연령대, 성별을 대상으로 한 홍보 강화 및 집중 전략 필요

Solution

전문가 등급제 및 가격 책정 기준표를 통해 서비스의 적정 가격 설정

고객에게 전문가 정보 열람 서비스 제공

전문가 등급 소개서		
	이름 홍길동	엑셀 VBA
기술 숙련도	보유 자격증	A
분야 경력	프로젝트 경험도	B
분야 학력	석사 졸업	A
고객 소통	고객과의 마찰 횟수	B
작업 속도	프로젝트 조기 완료율	C
팀원 간의 의사소통 능력	다년 간의 같은 팀원과의 5년 업력	A

전문가 특성

등급

가격 책정 기준표				
전문가 특성 카테고리	학위 및 경력	투입인력(명)	기간	인건비
등급별 책정 가격	A(박사) :30000 B(석사) :20000 C(학사) :10000	A(분야별 평균 인력풀의 2배수 이상) :10000 B(평균 인력풀) :70000 C(평균 인력풀 미만) :50000	A(계약 기간 중 료 전 완수) :1000 B(계약 기간 중 료에 완수) :700 C(기간 연장) :500	A(시장가격의 1배수 이상) :100 B(시장 적정가격):70 C(시장가격 미만):50

1. 전문가 특성 카테고리별로 등급에 따른 '가격 책정 기준표' 마련
2. 가격 책정 기준표를 토대로 '전문가 등급 소개서' 작성
3. '가격 책정 기준표'와 '전문가 등급 소개서'를 토대로 책정한 전문가 특성별 가격들을 합산하여 해당 거래의 서비스 최종 가격 확정



1. 고객은 명시된 가격 책정 기준을 확인해 상이한 가격의 원인 파악 가능
2. 고객은 여러 전문가들의 소개서를 열람 및 비교함으로써 자신의 니즈에 가장 부합하는 전문가 선택 가능

명확한 서비스 가격 책정으로 고객 불만 해소 기대

전문가 등급제 · 가격 책정 기준표 설계안

Solution

- IT 전문가 등급제·가격 책정 기준표로 책정 기준을 투명화 — 등급 소개서 열람·비교로 가격 불만 해소
- 헤비 고객 VIP 혜택 유지 + 중간층 프로모션 전환 유도, 20대·남성·유튜브 유입 중심 타겟 홍보 전략
- 신속 알람·프리미엄 서비스 무료 체험 및 기간별 할인으로 이용률 확대 제언

Project Overview

지역별 기상 데이터 기반 열수요 예측
2025.05 – 2025.06 (2개월) · 날씨 빅데이터 공모전 참가 · 팀장

Data

- 한국지역난방공사 19개 지사 × 2021–2023년 1시간 단위 열수요 실적 + AWS·ASOS 기상 관측 자료
- 학습 499,301행 × 12컬럼 · 테스트 166,915행
- 시계열 구조를 유지한 분할 — 2021–22년 학습 / 2023년 검증

Preprocessing

- 장비 오류값(-99.0, -9.9)을 결측으로 전환 후 도메인 지식 기반 6단계 결측 대체
- 체감온도 계산식 역산으로 기온·풍속 상호 유도, 일 강수량 누적 구조 활용, 시간대별 일사량 특성 반영(야간 0 대체) 등
- 체감온도 - 기온 상관 0.99 → 다중공선성 방지 위해 기온 변수 제거
- IQR 기반 이상치 탐지 - 제거/대체 버전을 각각 구성해 비교 실험 설계

My Role

- 4인 팀의 팀장으로 프로젝트 총괄
- 열수요·기상 데이터 전처리
- 도메인 기반 결측치·이상치 처리 방법 설계 및 비교 실험
- 전처리 버전별 스택킹 모델 성능 비교 및 최종 모델 선정

전처리 버전별 실험 (스태킹 모델 동일 구조)


전처리 버전	검증 RMSE	제출 RMSE	선택
결측치 대체 데이터	18.15	18.0	최종
결측치 대체 및 이상치 대체 데이터	18.04	18.3	—
결측치 대체 및 이상치 제거 데이터	17.4	—	—
원본 데이터	18.7	—	—

일반화 우선의 모델 선정

결측치 대체 및 이상치 제거 데이터는 검증 RMSE가 가장 낮았지만 예측값이 비정상적으로 낮아 과적합 의심

→ 검증 데이터와 테스트 데이터 성능이 일관된 결측치 대체 데이터를 최종 선택

Modeling & Result



Result

- Bi-LSTM·GRU·Transformer 실험 후 내삽+외삽 모델을 결합한 스택킹 앙상블 채택 (모든 모델 Optuna 튜닝 진행)

활용방안

- 열 생산·공급 계획 최적화
- 한파 등 피크 수요 선제 대응
- 재생 열원 공급 설계 근거 제공

Project Overview

Data


- Kaggle Quick, Draw! 데이터 중 30개 카테고리 simplified 데이터(약 20GB) 사용
- stroke 벡터를 이미지로 변환해 (32, 32, 1) 텐서 입력 구성

My Role

- EDA·데이터 전처리 및 클래스별 이미지 특성 분석
- LeNet-5 구조 설계·모델 개발 및 과적합 개선 실험
- 4개 CNN 모델 성능 비교 및 앙상블 모델 개발

CNN 기반 Doodle 이미지 분류

2024.09 – 2024.11 (2개월) · 팀원



Quick, Draw! 낙서 데이터 예시 (bee)


Modeling

- LeNet-5·AlexNet·GoogLeNet·VGG-16을 32×32 입력·30클래스에 맞게 직접 구조 축소 설계 (필터·strides·풀링·Dense 조정)
- EarlyStopping을 활용한 구간 과적합 확인
→ Dropout·데이터 증강·L2 정규화·배치 조정 실험

모델	파라미터	학습 시간	Accuracy
LeNet-5	63,406	2m 3s	0.8635
AlexNet	5,451,486	6m 10s	0.9227
GoogLeNet	143,342	4m 34s	0.9314
VGG-16	16,319,168	33m 18s	0.9379

PROJECT 06

Modeling & Result



모델별 학습 시간(좌) · 최종 Loss/Accuracy 비교(우)

앙상블 실험

Soft Voting 0.9503

Weighted Soft Voting 0.9514

Grid Search 가중 최적화 0.9517

Grid Search로 4개 모델 softmax 가중치 (0.1, 0.2, 0.4, 0.3) 탐색
→ 성능 높은 GoogLeNet·VGG-16에 높은 가중치 부여

Result

- 단일 모델 최고 성능(VGG-16 0.9379)을 넘어 **가중 Soft Voting 앙상블로 최종 Accuracy 0.9517 달성**
- **카테고리별 정확도 비교**를 통해 bread·piano 등 공통 취약 클래스를 확인하고, 모델별 예측 특성을 결합한 **앙상블 모델로 성능을 개선**

Project Overview

EDA

- 아동복: 상품 종류 2위(14,241개)인데 판매량은 최하위권(37,656건)
→ Ladieswear(677,475건) 대비 격차 뚜렷
- 구매 빈도: **연평균 2.2회**로 경쟁 패션앱(연 8.8~15.2회) 대비 낮음
- 패션뉴스 구독·커뮤니티 활동과 구매의 상관 0.05 수준
→ 기존 구독형 채널의 구매 견인 한계

Insight


- '텐 포켓' 트렌드·선행 연구 기반 **아동복 라인 리포지셔닝** - 연령대별 디자인 세분화·친환경 소재 강조
- **게이미피케이션 룩북·AI 가상피팅 도입**으로 온라인 재구매율 제고 (가상피팅 사례: 재구매율 +44%)

My Role

- 4인 팀의 **팀장**으로 프로젝트 총괄
- H&M 이커머스 데이터 전처리·EDA 및 고객 구매 행동 분석 수행
- 분석 결과와 선행 사례를 바탕으로 아동복 리포지셔닝 및 재구매율 제고 방안 제안

H&M 이커머스 데이터 기반 행동 구매 행동 분석

2025.03 (1개월) · 팀장



제품군 별 판매량 (좌) · 고객 정보와 구매량 간 상관관계 히트맵 (우)

패션 쇼핑물 모음 앱/서비스별 구매 형태 비교
[Base: 최근 3개월 내 각 패션 쇼핑물 모음 앱/서비스에서 구매한 자, N=각 200, 단일/중복 응답, %]

	MUSINSA	A B L Y	ZIGZAG	KREAM	29 CM
연 평균 구매 빈도	10.6회	15.2회	14.0회	8.8회	13.0회
1회 구매 시 지출 비용	96,900원	55,200원	67,200원	188,300원	112,700원
비교 서비스	크림(Kream) 29 29cm 에이블리 지그재그 W컨셉	지그재그 무신사 브렌디 29 29cm W컨셉	에이블리 무신사 29 29cm 브렌디 W컨셉	무신사 29 29cm 발란 머스트윳 W컨셉	무신사 W컨셉 지그재그 크림(Kream) 에이블리 SSF SHOP

출처 : 'MZ세대(1980년대 초 ~ 2000년대 초 출생) 패션 앱 트렌드 리포트 2024'

	avg_price	purchase_count	total_price
age_m			
10	14.131394	1.581120	22.056837
20	15.691221	2.276787	36.389231
30	16.227558	2.508790	41.402251
40	16.034028	2.379975	38.566295
50	17.121307	2.243051	38.606843
60	17.825120	2.058008	36.857581
70	17.927994	1.851121	33.341051
80	19.638425	1.861607	36.821920
90	17.617417	1.950000	32.693000

가격 달러(\$)

MZ 패션 쇼핑 앱의 연평균 구매율 (좌) · H&M 고객의 연평균 구매금액, 구매횟수, 합산금액 (우)

DATA ANALYST

ML ENGINEER

THANK YOU

끝까지 봐주셔서 감사합니다.

YI HYUN SONG

+82 10-8272-3776

leehyun3776@gmail.com



<https://github.com/Data-YihyunSong>



<https://velog.io/@leehyun3776>