DATA ANALYST

PORTFOLIO

데이터를 보고, 문제를 찾고, 더 나은 선택을 만듭니다.

사용자 행동과 비즈니스 데이터를 분석해 문제를 발견하고, 가설을 검증하고, 실제 업무에 활용되는 결과로 연결합니다.

송이현

YIHYUN SONG

CONTENTS

01 About Me

02 Strength

03 Education & Experience

04 Skills & Certificates

05 Projects

PROJECTS

01 **서비스 운영 데이터 분석 및 지표 대시보드·자동화 구축** — 실무

B2B SaaS 인턴 · SQL · Redash · n8n · LLM

02 **edX MOOC 수강생 행동 데이터 기반 퍼널·리텐션 분석 및 대시보드 구축**

64만 건 로그 · AARR 퍼널 · Tableau

03 **IT 아웃소싱 플랫폼 고객·거래 데이터 기반 매출 개선 분석** — 최우수상

12.4만 고객 · 매출 구조·가격 편차 분석

04 **H&M 이커머스 고객 구매 행동 분석**

제품군·구매 빈도 분석 · 재구매 전략

05 **라이프로그·건강조사 데이터 기반 치매 예측 및 비대면 인지검사 플랫폼 : 또릿**

통계 검정 · Bi-LSTM · Tableau · 시장성 분석

06 **CNC 센서 데이터 기반 불량 예측 - 평가 기준 설계와 실패 원인 분석**

FN 최소화 기준 · SHAP · 파생변수 실험

07 **기타 ML 프로젝트 - 지역별 열수요 예측 · Doodle 이미지 분류**

전처리 비교 실험 · 스태킹 · CNN 앙상블

ABOUT ME

'왜?'에서 시작해 액션으로 끝내는 데이터 분석가, 송이현입니다.

- B2B SaaS 운영팀에서 **운영 쿼리 20여 종·대시보드 4개·자동화 봇 4종**을 구축해 주간 지표 집계와 CS 확인 업무를 구조화하고, **1년치 고객 문의 데이터를 분석해 문서 개선 방향을 제안**했습니다.
- 64만 건 수강 로그의 **AARR 퍼널을 분석**해 **유입 후 26%·활성 후 48%가 이탈**하는 초기 구간을 특정하고, 12.4만 고객 거래 데이터에서는 **상위 2.7% 고객에 매출이 집중된 구조**와 동일 서비스의 가격 편차를 발견해 개선안을 제안했습니다.
- 분석 목적에 따라 카이제곱·상관분석 등 적절한 방법을 선택하고, 모델링에서는 Accuracy에만 의존하지 않고 FN과 Recall 등 **비즈니스에서 중요한 오류를 기준으로 결과를 해석**합니다. 분석 결과는 **비전문가 동료도 바로 활용할 수 있는 대시보드와 보고서**로 연결합니다.



학력	홍익대학교 컴퓨터공학과 (2021.03 – 2027.02 졸업 예정) · GPA 3.65/4.5
경력	Greybox · Project Management Intern (2025.11 - 2026.02) - 운영 데이터 분석·대시보드·자동화
교육	내일배움캠프 데이터분석 6기 수료 (2025.03 - 2025.07) · DSA Python 활용 실무 데이터 분석 (2023.11 - 2024.02)
자격·수상	PCSQL Lv4 (1000점) · SQLD · ADsP · GAIQ · AICE Associate · DSA Business Data Analysis Project 최우수상

STRENGTH

01 문제를 정의하고, 숫자로 확인합니다.

단순히 지표를 계산하는 데 그치지 않고 왜 이런 결과가 나왔는지 질문하고, 데이터를 통해 원인을 좁혀갑니다.

- 64만 건 수강 로그에서 **퍼널별 이탈을 분석**해 유입 후 26%·활성 후 48%가 이탈하는 구간을 특정
- 12.4만 고객 거래 데이터에서 상위 2.7% 고객의 **매출 집중 구조와 동일 서비스의 가격 편차**를 발견하고 **개선안 제안**
- 1년치 CS 문의 데이터에서 **반복 문의 패턴**을 찾아 **문서 누락 영역과 개선 방향 도출**

02 한 번의 분석을, 반복해서 쓰는 도구로 만듭니다.

분석 결과가 개인의 파일에 남는 것보다 팀이 계속 활용할 수 있는 형태로 만드는 것을 중요하게 생각합니다.

- B2B SaaS 운영을 위해 **Redash 쿼리 20여 종 구축 - 주간 운영 지표 정형화**
- 기간과 조건을 바꿔 사용할 수 있도록 **파라미터화된 쿼리·대시보드 구축**
- **Tableau KPI 대시보드 3종을 종합·마케팅·프로덕트 관점**으로 구성해 이해관계자별 지표 확인 지원

03 분석 방법보다, 문제에 맞는 기준을 먼저 봅니다.

같은 데이터라도 무엇을 놓치면 안 되는지에 따라 분석 방법과 평가 기준이 달라져야 한다고 생각합니다.

- 건강조사 209개 변수 → 30개를 **카이제곱·상관분석**으로 선별하고, **클래스 불균형을 고려**해 모델링
- CNC 불량 예측에서 불량을 양품으로 놓치는 FN을 최소화하는 기준으로 모델을 비교하고 **SHAP**으로 주요 원인 분석
- 열수요 예측에서 검증 성능만 높고 테스트 성능이 떨어지는 모델을 과적합 가능성으로 판단하고 **일반화 성능을 우선**해 모델 선택

04 분석을 실제 업무의 변화로 연결합니다.

분석 자체를 끝으로 보지 않고, 반복 업무는 자동화하고 결과는 누구나 활용할 수 있게 전달합니다.

- **n8n·LLM**을 활용해 자동화 봇 4종 구축
- CS 문의 **분석 결과를 보고서와 이해관계자별 대시보드로 정리**해 문서 개선 방향 제안
- 여러 프로젝트에서 팀장으로 **분석 방향 조율 → 결과 해석 → 발표** 수행

EDUCATION & EXPERIENCE

홍익대학교 컴퓨터공학과

2021.03 – 2027.02 (졸업 예정) · GPA 3.65/4.5

주요 이수 과목

기초데이터베이스 · 기계학습기초 · 기계학습심화 · 자료구조 · 알고리즘분석 · 객체지향프로그래밍 · 소프트웨어공학 · 운영체제 · 컴퓨터네트워크 · 정보보안

교육

내일배움캠프 데이터분석 6기

2025.03 – 2025.07

SQL · Python · 통계 · 머신러닝 · Tableau 실무 과정 이수

DSA Python 활용 실무 데이터 분석

2023.11 – 2024.02

Python 기반 데이터 전처리·분석 및 머신러닝 실무 과정 이수

Greybox | Project Management Intern

2025.11 – 2026.02 (3개월) · 고객 메시징 SaaS(Notifly) 운영팀

운영 데이터를 구조화하고, 반복 확인 업무를 데이터 도구로 바꿨습니다.

- **운영 지표 체계화**
MySQL·AWS Athena를 활용해 주간 프로덕트 지표 쿼리 20여 종을 구축하고 프로덕트 대시보드 운영에 활용

- **반복 조회 업무 대시보드화**
파라미터형 서비스 로그 대시보드·CS 대응 대시보드 4개를 설계해 문의 발생 시 반복하던 쿼리 실행과 화면 확인을 한 화면에서 조회할 수 있도록 구조화

- **CS 데이터 분석 및 개선안 도출**
2025년 고객 문의 데이터를 KoNLPy으로 분석해 반복 문의 패턴과 가이드 문서 누락 영역을 도출하고, 분석 결과를 보고서로 작성 및 발표

- **반복 운영 업무 자동화**
n8n 기반으로 트라이얼 만료 임박·사용량 임계치 도달 알림과 관련 대시보드 URL 자동 답글, 지식베이스 기반 답변 초안을 제공하는 CS 보조 봇 구축

- **AI 서비스 운영 및 데이터 지원**
AI 답변 품질 평가·QA 자동화 체계를 운영하고, 제휴 채널 제출을 위한 지표 정의 및 SQL 데이터 추출 수행

20+	4	4	1
운영 쿼리	대시보드	자동화 봇	분석 보고서 발표

SKILLS & CERTIFICATES

QUERY

MySQL · AWS Athena · Redash

- 데이터 추출
- 지표 설계
- 데이터 정합성 검증
- 쿼리 최적화

BI

Tableau · Redash · Google Sheets

- KPI 대시보드
- 지표 설계
- 데이터 시각화
- 분석 리포팅

AUTOMATION

n8n · LLM · RAG · OpenAI API

- 업무 자동화
- NLP
- AI 서비스 평가 및 운영
- 데이터 기반 워크플로우

ANALYSIS

Python · Pandas · NumPy

- EDA
- 퍼널
- 세그먼트 분석
- 가설검정
- 이상치 분석

MODELING

Scikit-learn · LightGBM · XGBoost · TensorFlow

- 분류
- 회귀
- 시계열 예측
- 하이퍼파라미터 튜닝
- 모델 해석

Certificates & Award

2026.09	AICE Associate
2026.08	PCSQL Lv4 (1000점)
2026.06	Google Analytics Certification
2025.06	SQLD
2025.03	ADsP
2024.02	**DSA Business Data Analysis Project 최우수상**

Tools GitHub · Jupyter · Colab · VS Code · AWS S3 · MongoDB

PROJECTS

사용자 및 고객 데이터 분석 4건과 실무 운영 데이터 프로젝트를 앞에, 모델링 중심 프로젝트를 뒤에 배치했습니다.

01 서비스 운영 데이터 분석 및 지표 대시보드·자동화 구축 — 실무
2025.11 – 2026.02 · 인턴
운영 쿼리 20여 종 · 대시보드 4개 · n8n/LLM 봇 4종 · 1년치 CS 문의 분석 보고서
SQL · Redash · n8n · LLM

02 edX MOOC 수강생 행동 데이터 기반 퍼널·리텐션 분석 및 대시보드 구축
2025.05 · 5인 팀
641,138건 로그 · 수료율 3.58% KPI · 유입 후 26%/활성 후 48% 이탈 구간 특정 · Tableau 대시보드 3종
Python · Tableau · AARR

03 IT 아웃소싱 플랫폼 고객·거래 데이터 기반 매출 개선 분석 — 최우수상
2023.11 – 2024.02 · 팀장
124,017명 고객 · 상위 2.7% 매출 집중 · 가격 IQR 편차 · 등급제/가격 기준표 제안
Python · EDA

04 H&M 이커머스 고객 구매 행동 분석
2025.03 · 팀장
연 2.2회 구매 빈도(경쟁앱 8.8~15.2회) · 아동복 판매 효율 최저 · 재구매 전략 제안
Python · EDA

05 라이프로그·건강조사 데이터 기반 치매 예측 및 비대면 인지검사 플랫폼 : 또릿
2025.05 – 2025.07 · 팀장
209→30개 변수 통계 선별 · 치매 Recall 0.86 · Tableau 대시보드 · TAM/SAM/SOM 분석
Python · Bi-LSTM · Tableau · GPT API

06 CNC 센서 데이터 기반 불량 예측 - 평가 기준 설계 및 실패 원인 분석
2025.05 · 팀장
불량 예측률 96.0% · FN 98건 최소 기준 선정 · SHAP 실패 100건 분석 → 파생변수 4종 실험
LightGBM · SHAP

07 기타 ML 프로젝트 - 지역별 열수요 예측 · Doodle 이미지 분류
2024.09 – 2025.06
전처리 4버전 비교 → 스태킹 RMSE 18.0 · CNN 4종 가중 앙상블 Accuracy 0.9517
Stacking · CNN

PROJECT 01

Project Overview

서비스 운영 데이터 분석 및 지표 대시보드·자동화 구축

2025.11 – 2026.02 (3개월) · Greybox 고객 메시징 SaaS(Notifly) 운영팀 · Project Management Intern

Problem

- 주간 프로덕트 지표를 **매주 수작업으로 집계**해 대시보드에 반영
- CS 문의마다 담당자가 **같은 쿼리·화면을 반복 확인** - 응대 시간은 늘고, 반복 문의의 원인은 남지 않음
- 무료 트라이얼 만료·데이터 사용량 초과를 **사람이 직접 모니터링**
- 반복 확인 업무를 쿼리·대시보드·봇으로 구조화하고, 1년치 문의 데이터로 개선 방향을 도출

My Role

- 주간 지표 쿼리 작성·최적화 및 프로덕트 대시보드 **주간 운영**
- **서비스 로그 대시보드**·CS 대응 **대시보드 설계**
- 2025년 CS 문의 데이터 수집·분석 및 **보고서 발표**
- n8n·LLM 기반 알림·응답 봇 4종 구축, AI 답변 품질 평가·QA 자동화

20+ 운영 쿼리

4 대시보드

4 자동화 봇

1년치 CS 문의 분석

Data

데이터	활용
메시지 발송 로그	주간 프로덕트 지표 · 사용량 모니터링
서비스 플랜·이용 데이터	매출 지표 · 신규/이탈 고객 분석
CS 문의 (2025년 전체)	문의 패턴 분석 · 가이드 개선
서비스 사용량 데이터	사용량 모니터링 · 알림 자동화

장기간 데이터 집계에 따른 비용을 고려해, 일 단위 결과를 Google Sheets에 누적하여 장기 집계에 활용

운영 데이터
MySQL · Athena · Slack

→

SQL 쿼리 최적화
Redash · 파티션프루닝

→

대시보드
프로덕트 · 서비스 로그 · CS 대응

→

자동화
n8n → Slack 알림·답글

→

분석·보고
CS 문의 분석 보고서 발표

Tech Stack: SQL · Redash · Google Sheets · Python (Pandas · KoNLPy) · OpenAI GPT API · n8n · Supabase · Slack

PROJECT 01

Dashboard

서비스 운영 데이터 분석 및 지표 대시보드·자동화 구축

2025.11 – 2026.02 (3개월) · Greybox 고객 메시징 SaaS(Notifly) 운영팀 · Project Management Intern

주간 프로덕트 지표 쿼리 체계 (Redash)

지표	집계 단위	쿼리 설계 포인트	활용
채널별 메시지 발송량	주차	주간 집계 기준을 쿼리에 명시	프로덕트 대시보드 주간 갱신
활성 캠페인 수 · 활성 유저여정 수	주차	활성 상태 정의를 조건절로 명시	기능 사용 현황 추적
과금 + 플랜 수익 Top N	월 · 프로젝트별 / 플랜별	과금 데이터의 집계 기준 통일	매출 추이 및 고객 현황 모니터링
이탈 · 신규 고객 리스트 및 카운트	월	전월 대비 상태 변화로 정의	고객 증감 모니터링
매출 Top 20 고객사 채널별 발송량	주차 × 채널 (피벗)	쿼리 단계에서 피벗하여 표 형태로 출력	발송량 변화 원인 추적
Data 사용량	일 → 시트 누적	Athena 파티션 프루닝으로 스캔 최소화	사용량 모니터링 및 알림

운영 대시보드 2종

서비스 로그 대시보드

프로젝트 식별자를 입력하면 관련 로그를 바로 조회할 수 있도록 파라미터형으로 구성하고, 식별자를 모를 경우 프로젝트 검색을 통해 연결

→ 개발자에게 확인하던 로그 조회 업무를 운영자가 직접 수행할 수 있도록 구조화

CS 대응 대시보드

문의 대응 과정에서 반복적으로 확인하는 주요 정보를 한 화면에서 조회할 수 있도록 구성

→ 문의 발생 시 봇이 관련 대시보드에 필요한 조건을 자동 적용해 답글로 제공

설계 원칙

- **일관된 지표 산출:** 기간 기준과 상태 정의를 쿼리에 명시해 실행 시점과 담당자에 관계없이 동일한 기준으로 집계
- **비용 효율화:** Athena 파티션 프루닝을 적용하고, 장기 집계가 필요한 데이터는 일 단위 결과를 누적해 활용
- **수작업 최소화:** 반복 입력하던 고객군별 채널 데이터를 쿼리 단계에서 피벗해 바로 활용할 수 있도록 구성

한계와 개선안

Redash와 원천 데이터만으로 프로덕트 지표를 완전히 자동 갱신하는 데에는 장기 집계 비용 측면의 한계가 있었음.

→ 반복적인 주간 집계를 안정적으로 자동화하려면 주간 집계용 데이터 마트 구축이 선행되어야 함을 확인하고, 후속 개선안으로 정리

PROJECT 01

Analysis & Automation

서비스 운영 데이터 분석 및 지표 대시보드·자동화 구축

2025.11 – 2026.02 (3개월) · Greybox 고객 메시징 SaaS(Notifly) 운영팀 · Project Management Intern

2025년 CS 문의 데이터 분석 → 보고서 발표

1. **수집** — Slack CS 채널의 문의와 담당자 답변 데이터를 시트·Supabase에 매일 자동 적재 (n8n)
2. **정제** — Pandas로 문의·답변 데이터를 정제하고 분석 가능한 구조로 가공
3. **분석** — KoNLPy 키워드 빈도 분석과 LLM 문의 분류를 활용해 반복 문의 패턴과 고객 Pain Point 도출
4. **도출** — 문의 데이터와 공식 가이드 문서를 비교해 문서 누락 영역을 조사하고 FAQ·문서 개선 방향 도출
5. **보고** — 분석 보고서 작성 후 팀 발표 → 반복 문의 패턴과 문서 개선 방향 공유

결과

- 반복 문의 패턴을 기반으로 FAQ·가이드 문서 개선 방향 제시 및 누락 영역 보완 제안
- 문의 유형 체계(ISSUE · HOWTO · CONCEPT · OTHER)를 정의해 자동 답변 봇의 응답 스타일 분기에 재사용

n8n · LLM 자동화 봇 4종

1 트라이얼 만료 알림 봇

Redash의 잔여 기간 데이터를 n8n으로 조회해 만료 임박 고객을 운영 채널에 자동 알림

2 사용량 초과 Alert 봇

고객사별 서비스 사용량을 매일 누적하고 사용량 임계치 도달 시 자동 알림

3 CS 보조 봇

CS 문의 발생 시 관련 대시보드 URL을 답글로 자동 제공해 담당자의 반복적인 쿼리·화면 확인 단계 축소

4 지식베이스 답변 봇

제품 지식베이스에서 관련 문서를 검색해 문의 유형별 답변 초안·셀프서브 가이드 제공

한계와 배움 LLM 답변 품질이 기대 수준에 미치지 않아 자동 응답의 실사용은 보류하고, 문서 검색 품질과 문의 데이터 축적이 선행되어야 함을 확인함. 이후 답변 평가 기준을 먼저 정의하고 QA 자동화를 통해 품질을 검증하는 구조로 개선 방향을 정리

PROJECT 02

Project Overview

edX MOOC 수강생 행동 데이터 기반 퍼널·리텐션 분석 및 대시보드 구축

2025.05 (1개월) · 5인 팀 · 팀원 - Tableau 대시보드 구축 · AARR 퍼널 분석 담당

Problem → KPI

- edX는 강의를 무료로 제공하고 **수료 인증서 발급에서만 수익**이 발생 → 수료율을 핵심 KPI로 정의
- 정제 후 **수강 385,155건 · 수강생 311,905명** 중 수료 13,802건
- 질문: 수료율은 왜 낮고, 어느 단계에서 누가 이탈하는가?

3.58 %

전체 수료율 (KPI) - 1인당 평균 1.23개 강의 등록

가설

H1 수료는 학력·인구통계보다 **학습 행동**(참여 일수·활동 수)에 좌우될 것이다.

H2 이탈은 **학습 초반**(첫 시청 전·초기 며칠)에 집중될 것이다.

H3 강의별로 **수강 목적**(인증서 vs 자기계발)이 달라 수료율 차이가 날 것이다.

Data & Process

원본 641,138건

2012–13 Harvard·MIT 16개 강의, 20개 컬럼

→

정제 → 385,155건

미시청자(38%)의 활동 지표는 0으로, 성적>100·수료자 0점·종료일<시작일 제거

→

파생변수 5종

학습 기간 · 학습 밀도 · 언어권(국적→공용어) · 강의 분야 · 연령

→

KPI · 퍼널 정의

수료율 KPI, registered→viewed→ndays_act>1→certified 4단계

My Role

- AARR 퍼널 설계·전환율 분석
- 종합·마케팅·프로덕트 Tableau 대시보드 구축
- 행동 지표 분석 및 액션 제안

Tech Stack: Python (Pandas · NumPy) | Matplotlib · Seaborn | Tableau | AARR 퍼널 | 상관 분석

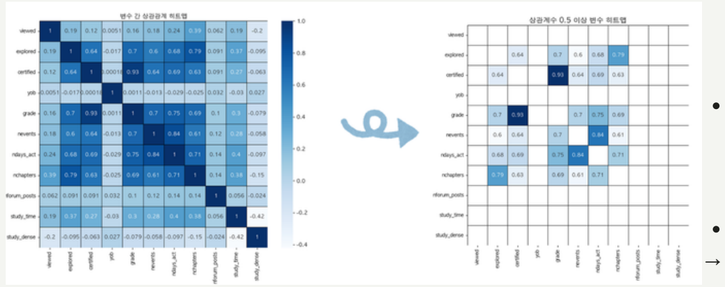
PROJECT 02

Hypothesis

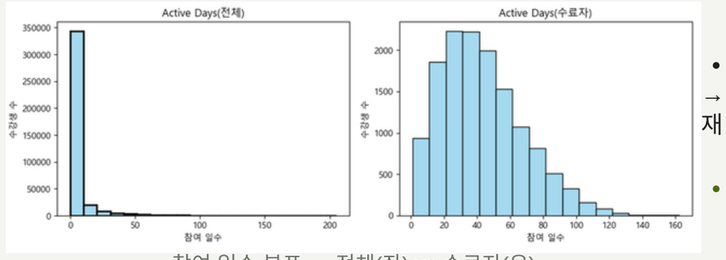
edX MOOC 수강생 행동 데이터 기반 퍼널·리텐션 분석 및 대시보드 구축

2025.05 (1개월) · 5인 팀 · 팀원 - Tableau 대시보드 구축 · AARR 퍼널 분석 담당

H1 검증 - 수료를 가르는 것은 행동 지표



수료 여부–지표 상관 히트맵 · 상관 0.5 이상 필터(우)

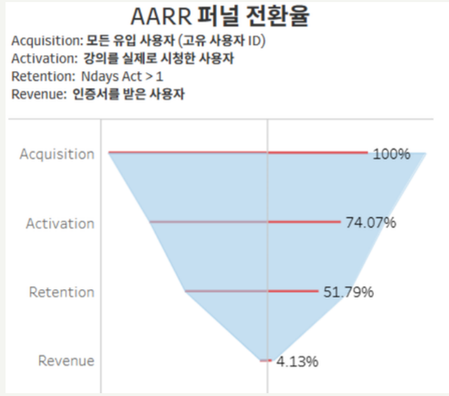


참여 일수 분포 — 전체(좌) vs 수료자(우)

- 수료 여부–성적 상관 **0.93**, 활동 지표 (nchapters · nevents · ndays_act · explored) 도 뚜렷한 양의 상관
- **학력 분포는 전체·수료자 간 차이 없음**
→ 인구통계보다 행동이 결정
- 전체 수강생은 참여 **0~10일**에 집중, 수료자는 0~100일에 고르게 분포
- 학습 기간·밀도 파생변수는 상관 낮음
→ 기준만 넘기면 수료 / 학습해도 미수료 유형이 혼재
- 대시보드 KPI와 퍼널 단계를 행동 지표 중심으로 설계

H1 채택

H2 검증 - 이탈은 초반에 몰린다



Acquisition — **100%**
유입 (고유 사용자)

Activation — **74.07%**
강의 실제 시청

Retention — **51.79%**
반복 활동 (2일 이상)

Revenue — **4.13%**
수료 인증서 취득

유입 후 **26%는 한 번도 시청하지 않고**, 활성 사용자의 **48%는 하루만 활동하고** 이탈
→ 병목은 초기 구간

H2 채택

H3 검증 - 강의마다 수강 목적이 다르다

- **컴퓨터 과학 입문**: 적극 참여율은 높지만 수료율 낮음 ↔ **Justice 등 대중 강의**: 수료자 多
→ 인증서 목적 수강생 비중이 강의마다 다름
- 다수 강의에서 **0~2 챕터 이후 수강 급감**이 공통 → 초기 콘텐츠 구간이 이탈 지점

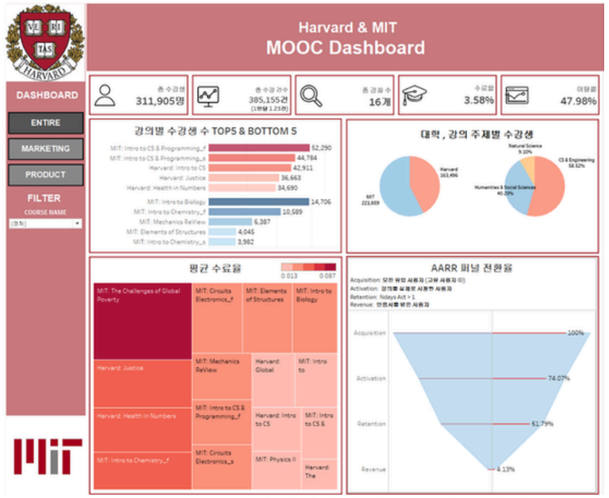
H3 채택

PROJECT 02

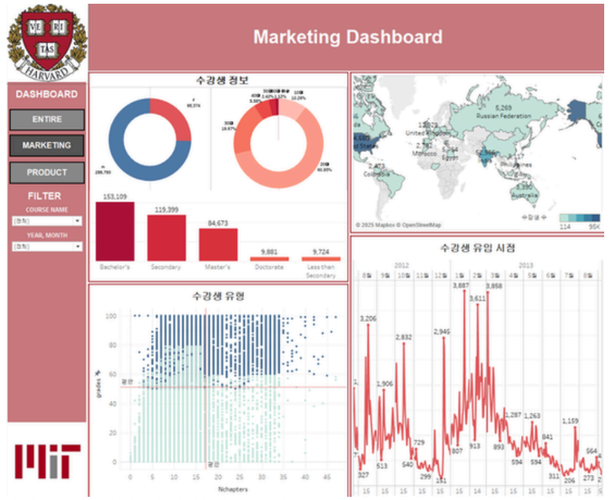
Dashboard

edX MOOC 수강생 행동 데이터 기반 퍼널·리텐션 분석 및 대시보드 구축

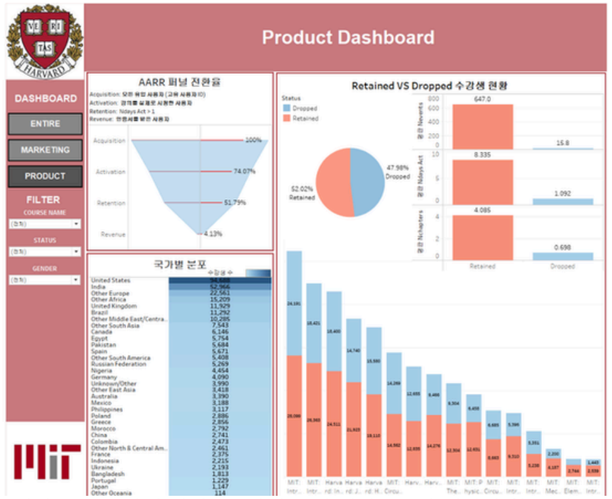
2025.05 (1개월) · 5인 팀 · 팀원 - Tableau 대시보드 구축 · AARR 퍼널 분석 담당



종합 대시보드 - Big Number · 인기/비인기 강의 · 수료율 트리맵 · AARR 퍼널



마케팅 대시보드 - 성별·연령·학력 · 수강생 4유형(학습×수료) · 국가 지도 · 월별 유입



프로덕트 대시보드 - 4단계 퍼널 · 국가별 유지/이탈 · 유지·이탈자 활동 지표 · 강의별 이탈률

이해관계자별로 필요한 질문이 달라 대시보드를 3개로 분리 - 강의 필터와 KPI Big Number를 연동해 특정 강의의 규모·수료율을 즉시 확인

Action - 프로덕트

- **온보딩**: 유입→첫 시청 전환 74% 개선을 위해 가벼운 콘텐츠를 먼저 노출
- **초기 1~3일 리텐션**: 챌린지·미션 구조 설계, 세그먼트별 리텐션 추적
- **이탈 사유 수집**: 이탈 시점에 NPS·간단 설문 삽입해 정성 데이터 확보
- **Revenue 지표 재정의**: 인증서 목적/비목적 수강생을 분리해 전환율 측정

Action - 마케팅

- **언어권 확장**: 영어·스페인어 외 포르투갈어·아랍어 사용 국가 비중 높음 → 자막 추가·현지화 마케팅
- **타겟 마케팅**: 남성은 컴퓨터 과학, 여성은 인문 강의에 집중 → 성별·연령별 추천·광고 운영
- **유형별 운영**: 학습O·수료X에는 리마인드·보상, 학습X에는 체험 콘텐츠, 수료자에는 심화 과정 추천
- **강의 포트폴리오**: 수요 많은 강의 정기 개설, 비인기 강의 수요 재조사 후 리뉴얼

PROJECT 03

Project Overview

IT 아웃소싱 플랫폼 고객·거래 데이터 기반 매출 개선 분석

2023.11 - 2024.02 (4개월) · 4인 팀 · 팀장

Problem → Goal

- L사: IT 전문가와 고객을 매칭하고 **거래 수수료**로 수익을 내는 플랫폼
- 월별 이용자 수 변동 폭이 커 **매출 유지가 어려운** 반면, 시장 의뢰 건수는 최근 3년 평균 **71.1% 성장**
- 목표: 소비자 니즈 기반 차별화 전략과 가격 측정 모델로 전분기 대비 매출 10% 증대

잠재 원인 → 분석 계획

잠재 원인	검증 데이터	분석 방법
동종 서비스 간 적정 가격 기준 부재	서비스명별 판매금액	분포 · IQR 이상치
소통 단절로 인한 거래 취소	거래취소 × 신속알람·프리미엄 가입	그룹 간 취소 수 비교
소수 고객에 의존하는 매출 구조	고객별 구매 건수 · 매출	구매 분포 · 집중도
타겟 고객 불명확	연령 · 성별 · 지역 · 유입경로	세그먼트 분포

Findings - 124,017명 고객 · 거래 데이터

IQR 밖

동일 서비스명 가격이 IQR을 크게 벗어남
→ 기준 없는 가격 편차가 고객 불만으로

2.7%

10건 이상 구매 고객은 전체의 2.7%
→ 매출이 소수 헤비 고객에 집중

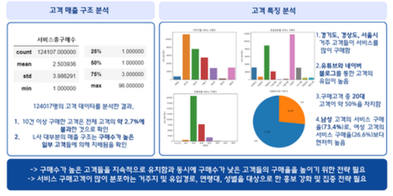
2배

프리미엄 미가입 전문가의 거래 취소 수가 가입자의 약 2배 · 신속 알람 미사용자 약 80%

50% · 73.4%

구매 고객의 20대 비중 약 50%, 남성 73.4%
- 유튜브·네이버 블로그 유입 다수





'홈페이지' 대분류는 판매수 1위이지만 **거래 취소율도 최고** → 취소를 줄이는 서비스 개선이 함께 필요

Tech Stack

Python (Pandas · NumPy) | Matplotlib · Seaborn | 분포·상관 분석 | IQR 이상치 | 세그먼트 분석

PROJECT 03

Solution

전문가 등급제 및 가격 책정 기준표를 통해 서비스의 적정 가격 설정 ⟷ **고객에게 전문가 정보 열람 서비스 제공**

전문가 등급 소개서



	이름 홍길동	엑셀 VBA
기술 숙련도	보유 자격증	A
분야 경력	프로젝트 경험도	B
분야 학력	석사 졸업	A
고객 소통	고객과의 마찰 횟수	B
작업 속도	프로젝트 조기 완료률	C
팀원 간의 의사소통 능력	다년 간의 같은 팀원과의 5년 협력	A

전문가 특성 ↓ 등급 ↓

가격 책정 기준표

전문가 특성 카테고리	학위 및 경력	투입인력(률)	기간	인건비
등급별 책정 가격	A(박사) :30000 B(석사) :20000 C(학사) :10000	A(분야별 평균 인력풀의 2배수 이상) :10000 B(평균 인력풀) :70000 C(평균 인력풀 미만) :50000	A(계약 기간 종료 전 완수) :1000 B(계약 기간 종료에 완수) :700 C(기간 연장) :500	A(시장가격의 1배수 이상) :100 B(시장 적정가격):70 C(시장가격 미만0:50

1.전문가 특성 카테고리별로 등급에 따른 **'가격 책정 기준표'** 마련

2. 가격 책정 기준표를 토대로 **'전문가 등급 소개서'** 작성

3. '가격책정기준표'와 '전문가 등급 소개서'를 토대로 책정한 **전문가 특성별 가격들을 합산하여 해당 거래의 서비스 최종 가격 확정**



1. 고객은 명시된 가격 책정 기준을 확인해 **상이한 가격의 원인 파악 가능**

2. 고객은 여러 전문가들의 소개서를 열람 및 비교함으로써 **자신의 니즈에 가장 부합하는 전문가 선택** 가능

명확한 서비스 가격 책정으로 고객 불만 해소 기대

전문가 등급제 · 가격 책정 기준표 설계안 — 고객에게 전문가 정보 열람 서비스 제공

판단의 전환

'가격을 통일하자'가 아니라 '기준을 공개하자'

분석 결과는 '동일 서비스의 가격 편차'였지만, 추가 조사 결과 숙련도·기간 연장 등으로 **가격 차이 자체는 불가피**했습니다.
그래서 편차를 없애는 대신 **가격 책정 기준을 고객에게 투명하게 보여주는 방향**으로 제안을 수정했습니다.

1 전문가 등급제 · 가격 기준표

기술 숙련도·경력·고객 소통·작업 속도 등 특성별 등급으로 가격 산정 기준을 명시
→ 고객이 기준을 확인하고 전문가 소개서를 비교해 선택

2 세그먼트별 고객 전략

헤비 고객(2.7%)은 마일리지·수수료 감면으로 유지, 중간층은 재구매 프로모션으로 VIP 전환, 20대·남성·유튜브 유입 중심 타겟 홍보

3 거래 취소 감소

신속 알람 1개월 무료 체험 후 유료 전환 + 기간별 할인, 프리미엄 활성화 · '홈페이지' 대분류 세분화, 비전문가 의뢰서 작성 지원

PROJECT 04

Project Overview

2025.03 (1개월) · 4인 팀 · 팀장 - 전처리·EDA·구매 행동 분석 총괄

Question

매출을 늘릴 여지는 **어느 제품군**, **어느 구매 행동**에 있는가?

→ 고객·상품·거래 데이터로 **구매 효율이 낮은 지점**을 찾는다

37,656건

아동복 판매량 - 상품 종류는 2위(14,241개)인데 판매는 최하위. Ladieswear 677,475건 대비 격차 뚜렷

→ **구색 대비 판매 효율 최저**

연 2.2회

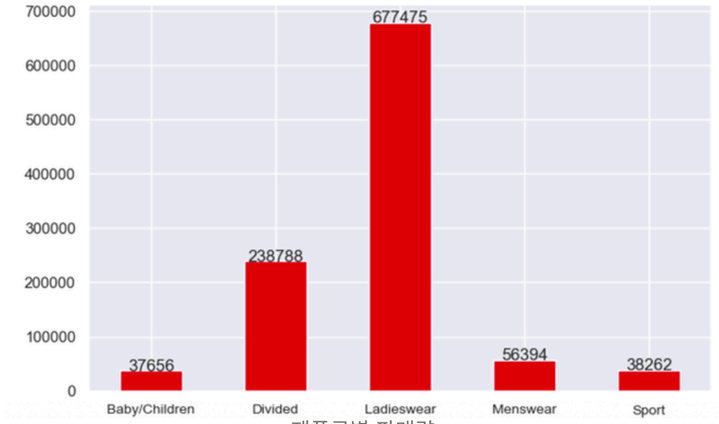
고객 1인 연평균 구매 빈도 - 경쟁 패션앱 연 8.8~15.2회 대비 크게 낮음

→ **재구매 유도가 핵심 레버**

상관 0.05

패션뉴스 구독·커뮤니티 활동과 구매량의 상관

→ **기존 구독형 채널로는 구매 견인 한계**



제품군별 판매량



고객 정보–구매량 상관 히트맵



age_m	avg_price	purchase_count	total_price
10	14.131394	1.581120	22.056837
20	15.691221	2.276787	36.389231
30	16.227558	2.508790	41.402251
40	16.034028	2.379975	38.566295
50	17.121307	2.243051	38.606843
60	17.825120	2.058008	36.857581
70	17.927994	1.851121	33.341051
80	19.638425	1.861607	36.821920
90	17.617417	1.950000	32.693000

MZ 패션앱 연평균 구매율 vs H&M 고객 연평균 구매금액·횟수

Action

- **아동복 리포지셔닝**: '텐 포켓' 트렌드 기반 연령대별 디자인 세분화·친환경 소재 강조
- **재구매율 제고**: 게이미피케이션 룩북 · AI 가상피팅 도입 (도입 사례 재구매율 +44%)

Tech Stack

Python (Pandas · NumPy) | Matplotlib · Seaborn | 상관 분석

PROJECT 05

Project Overview

라이프로그·건강조사 데이터 기반 치매 예측 및 비대면 음성 인지검사 플랫폼 : 또릿

2025.05 – 2025.07 (3개월) · 4인 팀 · 팀장 - 데이터 분석·모델링·대시보드 총괄

Problem - 통계로 확인한 문제

32.13%
부산 60세 이상 인구 비율
7개 특·광역시 중 1위

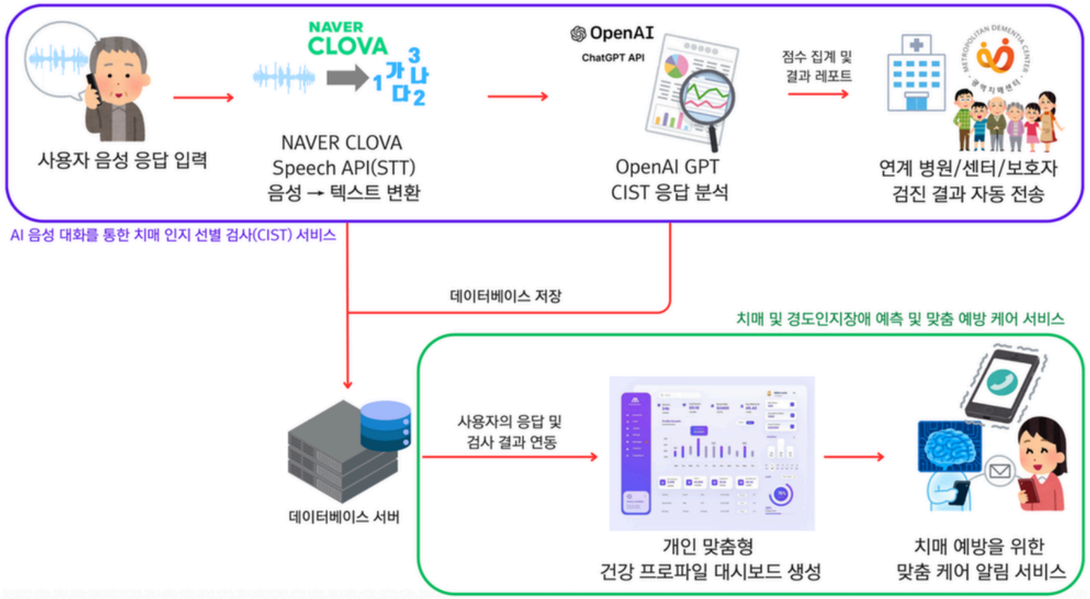
7% · 10%
60세 이상 · 65세 이상
치매 유병률

23.9%
시민이 꼽은 가장 도움 되는
서비스 1위 '치매 검진'

- 산복도로·구릉지 거주 고령자의 **의료기관 이동 제약**, 기존 CIST 검사는 **대면 방문·전문 인력 의존**, 종이 문진표라 데이터 축적 불가
- 음성으로 수행하는 비대면 AI CIST 검사 + 라이프로그 기반 위험도 예측·관리 플랫폼

My Role

- 4인 팀 팀장 - 문제 정의·일정·발표 총괄
- 라이프로그·건강조사 데이터 전처리, 통계 검정 기반 변수 선별, 예측 모델링
- Tableau 대시보드 4종 설계 (활동·수면 / 위험도 / 전화 인지검사 / 예방 게임)



음성 응답 → CLOVA STT → GPT 기반 CIST 채점 → 결과 전송·맞춤 케어 — 응답·결과는 DB에 저장되어 대시보드와 연동

기존 CIST 대비 바뀌는 것

접근성 의료기관 방문 → 어디서든 비대면
인력 전문 인력 직접 개입 → 검사자 1명이 더 많은 대상자
데이터 종이 문진 → 결과가 DB에 축적돼 추적·분석 가능

Tech Stack: Python (Pandas) · Scikit-learn · TensorFlow · Keras (Bi-LSTM) · SMOTE · Optuna · 카이제곱 검정 · Tableau · CLOVA Speech API · OpenAI GPT API

PROJECT 05

EDA

라이프로그·건강조사 데이터 기반 치매 예측 및 비대면 음성 인지검사 플랫폼 : 또릿

2025.05 – 2025.07 (3개월) · 4인 팀 · 팀장 - 데이터 분석·모델링·대시보드 총괄

Data

라이프로그 (AI Hub) - 웨어러블 수면·활동 데이터
39,300행 × 105열 · 약 4개월 수집분

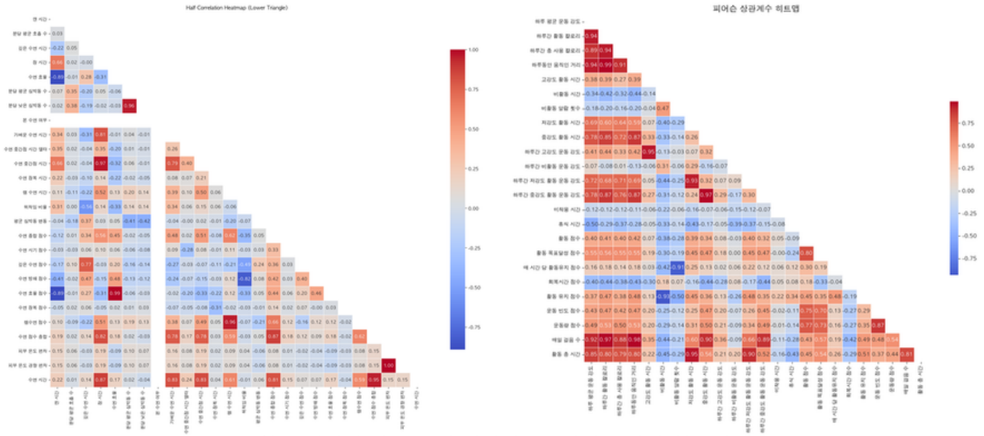
지역사회건강조사 (질병관리청) - 1:1 면접 설문
14,516행 × 209열

Process

- 라벨 데이터와 **이메일 PK 기준 JOIN** → 진단(치매/정상) 컬럼 생성, ACT·SLEEP은 이메일+날짜 기준 병합
- 응답 코드 정제 -7·77·777, 9·99·999는 결측, 8·88·888은 0으로
- IQR 이상치는 중앙값 대체
- 흡연·우울 점수 파생변수
- **카이제곱 검정**(범주형)·**상관 분석**(연속형)으로 209 → 가이드라인 81 → **모델링용 30개 변수** 선별
- SMOTE로 클래스 불균형 보정 (치매 56 → 85 시퀀스)

209 → 30

통계 검정·상관 기반 변수 선별



활동 데이터(좌) · 수면 데이터(우) 피어슨 상관 히트맵

검정 결과 상위 변수

카이제곱 통계량 상위: **정신 건강·수면 건강 지표**
연속형: 인지장애 경험과 만 나이는 매우 약한 음의 상관

EDA Insight

- **치매군**은 전체 수면 시간은 길지만 **깊은 수면·REM 수면이 짧고 수면 효율이 낮음** → 수면 효율·뒤척임 비율을 핵심 시계열 Feature로
- 활동 시간·운동량·활동 점수 간 강한 양의 상관, 비활동 시간과 활동 유지 지표는 강한 음의 상관 → 중복 변수 정리
- 두 집단 모두 **겨울철(12월) 운동 강도 급감** → 계절 요인을 감안한 알림 설계 필요
- **비활동 알람을 6회 받은 그룹**의 고강도 활동 시간·운동량 점수가 가장 높고 최솟값도 높음

→ **알림이 활동 유도에 효과** - 케어 알림 기능의 근거

PROJECT 05

Modeling & Dashboard

라이프로그·건강조사 데이터 기반 치매 예측 및 비대면 음성 인지검사 플랫폼 : 또릿

2025.05 – 2025.07 (3개월) · 4인 팀 · 팀장 - 데이터 분석·모델링·대시보드 총괄

평가 기준 → 모델 선택

- 조기 선별 서비스는 **치매 환자를 놓치는 오류(FN)가 더 치명적** → 소수 클래스 Recall 중심으로 최적화
- 트리 모델 5종(Optuna 튜닝)은 행을 독립 샘플로 다뤄 **시계열 의존성을 반영 못함** - 치매 Recall 최고 0.56
- ACT·SLEEP을 날짜 기준으로 묶은 **3차원 시퀀스(122일 × 50변수)** 를 Bi-LSTM에 입력 + SMOTE + 튜닝

모델	치매 Recall	F1
Random Forest	0.55	0.59
LightGBM	0.55	0.59
CatBoost	0.56	0.59
AdaBoost	0.39	0.44
Bi-LSTM (최종)	**0.86**	**0.63**

정상군 Precision 0.95 · Accuracy 0.79

0.86

치매 판별 Recall — 트리 모델 대비 +0.30



Tableau 대시보드 — 활동·수면 / 치매 위험도 / 전화 인지검사 결과 / 치매 예방 게임 — 개인별 추이를 실시간 확인

시장성 검증 — TAM · SAM · SOM

6,148억

TAM

전체 인구 5,175만 × 월 990원 × 12개월

1,446억

SAM

60세 이상 1,217만 명 기준

93억

SOM

부산 노인 78만 명 = 전국의 6.41%

Result

- CLOVA STT + GPT 기반 **음성 CIST 검사 파이프라인** 구현 — 비대면 전화 검사 서비스
- 개인별 위험도·검사 결과·수면/활동 추이 **대시보드 4종**과 맞춤 케어 알림으로 연결

한계와 배움 건강조사 데이터는 설문 특성상 최종 모델에 쓰지 못했고, 시퀀스 표본(170개)이 적어 Recall 대비 Precision(0.50)이 낮음 → 실사용 데이터 확보(의료기관·지자체 협업)와 판단 근거 설명(XAI)이 다음 과제

PROJECT 06

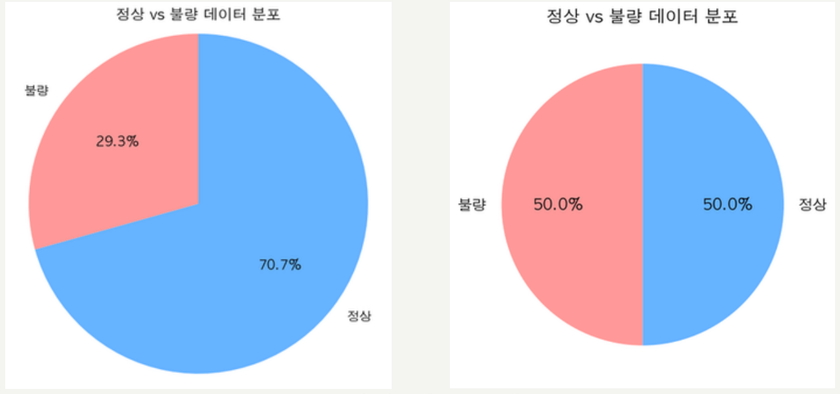
Project Overview

CNC 센서 데이터 기반 불량 예측 — 평가 기준 설계 및 실패 원인 분석

2025.05 (1개월) · 5인 팀 · 팀원 - 전처리 · LightGBM/DNN/CNN 모델링 · SHAP 실패 분석 · Feature Engineering

Problem & Data

- 자동차 부품 CNC 가공 공정 - **불량 원인 파악이 어렵고 공정 중 사전 예측 불가**, 데이터 기반 의사결정 체계 부재
- 장비 센서(위치·속도·가속도·전류·전압·파워) **25개 실험 + 조건/품질 데이터 26개 테이블**, 1초 주기 수집
- 라벨: 공정 완료 + 육안검사 통과 = 양품(1), 그 외 불량(0) - **양품 70.7% : 불량 29.3%** 불균형
- SMOTE로 50:50 보정 · MinMaxScaler 정규화 후 학습



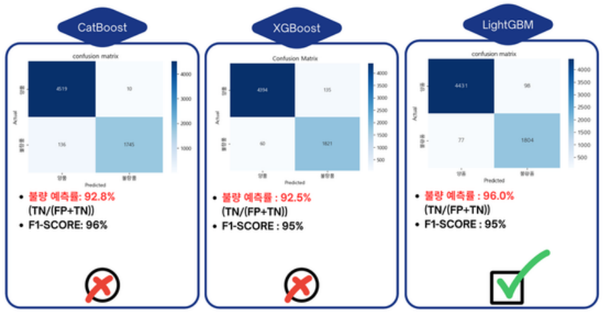
SMOTE 전(좌) · 후(우) 클래스 분포

평가 기준 설계

Accuracy가 아니라 '불량을 양품으로 내보내는 실패'를 센다

제조 공정에서 치명적인 오류는 **FN(불량 → 양품 판정)**. 따라서 모델 비교 기준을 **불량 예측률 TN/(FP+TN) · F1 · FN 개수**로 설계하고, 같은 F1이라도 FN이 적은 모델을 선택

모델	불량 예측률	F1	FN
CatBoost	92.8%	96%	–
XGBoost	92.5%	95%	–
GBM	95.7%	95%	132
AdaBoost	95.6%	95%	102
LightGBM (최종)	**96.0%**	**95%**	**98**



부스팅 5종 Confusion Matrix 비교

96.0%

불량 예측률 · F1 95% · FN 98건으로 최소

딥러닝
DNN Accuracy **0.887** → **0.967**(학습률·Dropout·손실함수·배치 조정),
1차원 신호를 STFT 스펙트로그램으로 바꾼 CNN(ResNet-50) **0.910** → **0.951**

Tech Stack: Python · LightGBM · XGBoost · CatBoost · SMOTE · MinMaxScaler · SHAP · DNN · CNN (ResNet-50) · STFT

PROJECT 06

SHAP Analysis

CNC 센서 데이터 기반 불량 예측 — 평가 기준 설계 및 실패 원인 분석

2025.05 (1개월) · 5인 팀 · 팀원 — 전처리 · LightGBM/DNN/CNN 모델링 · SHAP 실패 분석 · Feature Engineering



SHAP Summary Plot(좌) · 예측 실패 케이스 Waterfall 분석 — FN(좌)·FP(우)

실패 원인 분석

- SHAP Summary에서 **M_CURRENT_FEEDRATE의 영향이 압도적** - 다른 변수 대비 기여도 편중
- **예측 실패 100건**을 Waterfall로 개별 분석 → 모든 실패 사례에서 해당 변수의 강한 음의 영향 확인
- 가설: 특정 변수 과의존이 실패의 주원인 → 물리적 관계를 반영한 파생변수로 의존도를 분산하면 FN이 줄어들 것

Feature Engineering 실험

속도·전류·부하·토크의 물리적 관계를 반영한 파생변수 4종 - Torque_Estimate · Load_Increase · Velocity_Current_Ratio · Velocity_Power_Ratio

실험	불량 예측률	F1	FN
기존 변수 (선정 유지)	**96.0%**	95%	**98**
기존 + 파생변수 병합	95.1%	95%	104
파생변수 4개 단독	93.6%	89%	304

결론

- 가설은 **부분 기각** - 파생변수 병합 시 Torque_Estimate가 SHAP 중요도 2위로 올라 의존도는 분산됐지만 FN은 98 → 104로 줄지 않음
- 파생변수 단독은 FN 304로 불충분 → **기존 변수 세트를 유지**하고 파생변수는 해석 보조로 활용
- '성능 비교 → 실패 원인 분석 → 가설 → 재검증'의 루프를 한 번 돌며, **좋아 보이는 아이디어도 숫자로 기각**하는 기준을 세움

Tech Stack: Python · LightGBM · XGBoost · CatBoost · SMOTE · MinMaxScaler · SHAP · DNN · CNN (ResNet-50) · STFT

PROJECT 07

Additional ML Projects

지역별 기상 데이터 기반 열수요 예측 · CNN 기반 Doodle 이미지 분류

2025.05 – 2025.06 날씨 빅데이터 공모전 (팀장) · 2024.09 – 2024.11 (4인 팀 · 팀원)

지역별 기상 데이터 기반 열수요 예측

한국지역난방공사 19개 지사 × 2021–2023 1시간 단위 열수요 + AWS·ASOS 기상 관측
-학습 499,301행 · 테스트 166,915행 · 2021–22 학습 / 2023 검증 (시계열 분할)

전처리 버전별 비교 실험 (동일 스태킹 구조)

전처리 버전	검증 RMSE	제출 RMSE	선택
결측치 대체	18.15	**18.0**	**최종**
결측치 대체 + 이상치 대체	18.04	18.3	–
결측치 대체 + 이상치 제거	17.4	–	과적합 의심
원본	18.7	–	–

- 장비 오류값(-99.0, -9.9)을 결측으로 전환 후 **도메인 기반 6단계 대체** — 체감온도 식 역산으로 기온·풍속 상호 유도, 야간 일사량 0 처리 등
- 체감온도–기온 상관 0.99 → **다중공선성 방지 위해 기온 제거**
- **이상치 제거 버전은 검증 RMSE가 가장 낮았지만 예측값이 비정상적으로 낮아 과적합으로 판단** → 검증·테스트 성능이 일관된 버전을 최종 선택
- XGBoost(내삽) · CatBoost(범주) · Lasso(외삽) → LightGBM 메타 모델 2단 스태킹, 전 모델 Optuna 튜닝

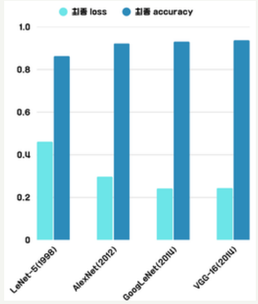
RMSE 18.0

최종 제출 성능 - 일반화 우선 선택

CNN 기반 Doodle 이미지 분류

Kaggle Quick, Draw! 30개 카테고리 simplified 데이터(약 20GB) - stroke 벡터를 32×32×1 텐서로 변환

모델 (직접 축소 설계)	파라미터	학습 시간	Accuracy
LeNet-5	63,406	2m 3s	0.8635
AlexNet	5,451,486	6m 10s	0.9227
GoogLeNet	143,342	4m 34s	0.9314
VGG-16	16,319,168	33m 18s	0.9379
가중 Soft Voting 앙상블	4 모델	Grid Search	**0.9517**



모델별 최종 Loss/Accuracy

- EarlyStopping으로 과적합 구간 확인 → Dropout · 증강 · L2 · 배치 조정 실험
- softmax 가중치 **(0.1, 0.2, 0.4, 0.3)** Grid Search - 성능 높은 GoogLeNet·VGG-16에 높은 가중치
- 카테고리별 정확도 비교로 **bread·piano 등 공통 취약 클래스** 확인 → 모델별 예측 특성을 결합해 단일 최고(0.9379) 초과

Tech Stack: Python · LightGBM · XGBoost · CatBoost · Lasso · 스태킹 앙상블 · Optuna · TensorFlow · Keras · Google Colab

DATA ANALYST

THANK YOU

끝까지 봐주셔서 감사합니다.

YI HYUN SONG

Phone +82 10-8272-3776

Email leehyun3776@gmail.com

GitHub github.com/Data-YihyunSong

Blog velog.io/@leehyun3776